

第4章 超越梯度下降

第3章介绍了梯度下降法。梯度下降法基于函数局部一阶特性。一阶近似是粗糙的，这种粗糙带来了一些问题。本章将介绍函数在局部的二阶特性。基于二阶特性分析函数在局部的性质。

本章首先回顾一些矩阵的相关知识，之后介绍如何在局部对函数进行二阶近似。有了函数的二阶近似就可以确定驻点的类型：极小点、极大点或者鞍点。之后本章介绍对原始梯度下降法的一些改进，这些改进有助于提高收敛速度，防止震荡或发散，规避局部极小。

最后，本章介绍两个基于函数二阶特性的优化算法：牛顿法和共轭方向法。然后介绍用牛顿法训练逻辑回归模型。二阶算法虽然不常用在神经网络和深度学习的训练中。阅读完本章，读者应该对函数的局部形态有更深刻的理解。

4.1 矩阵

首先回顾一下矩阵。这不是一个关于矩阵的全面介绍，例如行列式这个概念就没有出现。本节只介绍一下后文讨论中用得上的相关知识。

4.1.1 矩阵基础

矩阵是实数构成的2维阵列。以一个 3×3 矩阵为例：

$$\mathbf{A} = \begin{pmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{pmatrix} = (\mathbf{a}_{*1} \quad \mathbf{a}_{*2} \quad \mathbf{a}_{*3}) = \begin{pmatrix} \mathbf{a}_{1*}^T \\ \mathbf{a}_{2*}^T \\ \mathbf{a}_{3*}^T \end{pmatrix} \quad (4.1)$$

式(4.1)囊括了本书用到的对矩阵的各种表示。本书用大写粗斜体字母表示矩阵，例如 \mathbf{A} 。 a_{ij} 是实数，是矩阵 \mathbf{A} 的第 i 行、第 j 列元素。 \mathbf{a}_{*j} 是矩阵的第 j 列，它是一个列向量：

$$\mathbf{a}_{*j} = \begin{pmatrix} a_{1j} \\ a_{2j} \\ a_{3j} \end{pmatrix} \quad (4.2)$$

\mathbf{a}_{i*} 是矩阵的第 i 行，它是一个列向量：

$$\mathbf{a}_{i*} = \begin{pmatrix} a_{i1} \\ a_{i2} \\ a_{i3} \end{pmatrix} \quad (4.3)$$

式(4.1)中对 \mathbf{a}_{i*} 进行了转置，以表示一行。矩阵的行数和列数不一定相等，可以是 $m \times n$ ， $m \neq n$ 。表示成：

$$\mathbf{A}_{m \times n} = \begin{pmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{m1} & \cdots & a_{mn} \end{pmatrix} \quad (4.4)$$

一般可省略下标 $m \times n$ 。两个相同形状的矩阵可以相加：

$$\mathbf{A} + \mathbf{B} = \begin{pmatrix} a_{11} + b_{11} & \cdots & a_{1n} + b_{1n} \\ \vdots & \ddots & \vdots \\ a_{m1} + b_{m1} & \cdots & a_{mn} + b_{mn} \end{pmatrix} \quad (4.5)$$

矩阵相加就是把相应元素相加。可以用实数（标量）乘一个矩阵：

$$k\mathbf{A} = \begin{pmatrix} ka_{11} & \cdots & ka_{1n} \\ \vdots & \ddots & \vdots \\ ka_{m1} & \cdots & ka_{mn} \end{pmatrix} \quad (4.6)$$

$-\mathbf{A}$ 就是 $(-1)\mathbf{A}$ 。显然有 $\mathbf{A} - \mathbf{A} = \mathbf{A} + (-\mathbf{A}) = \mathbf{O}$ 。 \mathbf{O} 是所有元素都为0的矩阵——零矩阵。矩阵 \mathbf{A} 的转置定义为：

$$\mathbf{A}^T = \begin{pmatrix} a_{11} & \cdots & a_{m1} \\ \vdots & \ddots & \vdots \\ a_{1n} & \cdots & a_{mn} \end{pmatrix} = (\mathbf{a}_{1*} \quad \mathbf{a}_{2*} \quad \mathbf{a}_{3*}) = \begin{pmatrix} \mathbf{a}_{*1}^T \\ \mathbf{a}_{*2}^T \\ \mathbf{a}_{*3}^T \end{pmatrix} \quad (4.7)$$

\mathbf{A}^T 把 \mathbf{A} 的行当做列，列当做行。如果 \mathbf{A} 是 $m \times n$ 的，那么 \mathbf{A}^T 就是 $n \times m$ 的。

如果矩阵 \mathbf{A} 是 $m \times n$ 的，它可以与一个 n 维向量 \mathbf{x} 相乘：

$$\mathbf{Ax} = \sum_{j=1}^n x_j \mathbf{a}_{*j} \quad (4.8)$$

矩阵 \mathbf{A} 乘向量 \mathbf{x} ，使用 \mathbf{x} 的元素对矩阵的列进行线性组合。所以 \mathbf{A} 的列数和 \mathbf{x} 的维数必须相同。得到的结果是一个 m 维向量。容易看出 \mathbf{Ax} 的第 i 个元素是 $\sum_{j=1}^n x_j a_{ij} = \mathbf{a}_{i*}^T \mathbf{x}$ ，即 \mathbf{A} 的第 i 行与 \mathbf{x} 的内积。

有了矩阵和向量相乘的定义，就可以定义矩阵与矩阵相乘：

$$\mathbf{AB} = (\mathbf{Ab}_{*1} \quad \mathbf{Ab}_{*2} \quad \cdots \quad \mathbf{Ab}_{*k}) \quad (4.9)$$

\mathbf{A} 与 \mathbf{B} 的乘积是矩阵 \mathbf{AB} 。 \mathbf{AB} 的第 j 列是 \mathbf{A} 与 \mathbf{B} 的第 j 列 \mathbf{b}_{*j} 的乘积。如果 \mathbf{A} 是 $m \times n$ 的，那么 \mathbf{b}_{*j} 必须是 n 维向量，即 \mathbf{B} 必须为 n 行。 \mathbf{B} 的列数任意，例如 k 。所以要能够与 $m \times n$ 的 \mathbf{A} 相乘， \mathbf{B} 的形状必须是 $n \times k$ ， k 任意。结果 \mathbf{AB} 的形状是 $m \times k$ 。 \mathbf{AB} 的第 i 行、第 j 列元素是：

$$\mathbf{a}_{i*}^T \mathbf{b}_{*j} = \sum_{s=1}^n a_{is} b_{sj} \quad (4.10)$$

仅从形状上看 \mathbf{B} 与 \mathbf{A} 不一定能够相乘，因为 k 不一定等于 m 。就算 $k = m$ ， \mathbf{BA} 也不一定等于 \mathbf{AB} 。即矩阵乘法不满足交换律。一个反例就可以证明这一点。这里不再赘述。

矩阵的乘法满足结合率：

$$(\mathbf{AB})\mathbf{C} = \mathbf{A}(\mathbf{BC}) \quad (4.11)$$

矩阵乘法对加法满足结合律：

$$\mathbf{A}(\mathbf{B} + \mathbf{C}) = \mathbf{AB} + \mathbf{AC}, \quad (\mathbf{A} + \mathbf{B})\mathbf{C} = \mathbf{AC} + \mathbf{BC} \quad (4.12)$$

矩阵乘法对数乘有：

$$\mathbf{A}(k\mathbf{B}) = (k\mathbf{A})\mathbf{B} = k(\mathbf{AB}) \quad (4.13)$$

矩阵的数乘满足分配率：

$$k(\mathbf{A} + \mathbf{B}) = k\mathbf{A} + k\mathbf{B}, \quad (k + h)\mathbf{A} = k\mathbf{A} + h\mathbf{A} \quad (4.14)$$

矩阵乘积的转置是：

$$(\mathbf{AB})^T = \mathbf{B}^T \mathbf{A}^T \quad (4.15)$$

上述几个结论的证明很简单，只需要检查一下矩阵元素的表达式。向量 \mathbf{x} 的转置 \mathbf{x}^T 可以乘一个矩阵 \mathbf{A} ：

$$\mathbf{x}^T \mathbf{A} = (\mathbf{A}^T \mathbf{x})^T \quad (4.16)$$

行数和列数相同的矩阵是方阵。方阵 \mathbf{A} 的对角线元素之和称为它的迹（trace）：

$$\text{tr}(\mathbf{A}) = \sum_{i=1}^n a_{ii} \quad (4.17)$$

方阵 \mathbf{A} 和 \mathbf{B} 的乘积 \mathbf{AB} 的迹等于 \mathbf{BA} 的迹：

$$\text{tr}(\mathbf{AB}) = \sum_{i=1}^n \mathbf{a}_{i*} \mathbf{b}_{*i} = \sum_{i=1}^n \sum_{j=1}^n a_{ij} b_{ji} = \sum_{j=1}^n \sum_{i=1}^n b_{ji} a_{ij} = \sum_{j=1}^n \mathbf{b}_{j*} \mathbf{a}_{*j} = \text{tr}(\mathbf{BA}) \quad (4.18)$$

如果一个 $n \times n$ 的方阵的对角线元素为 1，其余元素都是 0，那么它是单位阵：

$$\mathbf{I}_{n \times n} = \begin{pmatrix} 1 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & 1 \end{pmatrix} \quad (4.19)$$

容易验证对于任何矩阵 $\mathbf{A}_{m \times n}$ ， $\mathbf{I}_{m \times m} \mathbf{A}_{m \times n} = \mathbf{A}_{m \times n} \mathbf{I}_{n \times n} = \mathbf{A}_{m \times n}$ 。在上下文很清晰时一般省略 \mathbf{I} 的下标。

4.1.2 矩阵的逆

令 \mathbf{A} 是 $n \times n$ 方阵，如果存在 $n \times n$ 方阵 \mathbf{A}^{-1} 满足：

$$\mathbf{A}\mathbf{A}^{-1} = \mathbf{A}^{-1}\mathbf{A} = \mathbf{I} \quad (4.20)$$

则称 \mathbf{A} 是可逆的。 \mathbf{A}^{-1} 是 \mathbf{A} 的逆矩阵。 \mathbf{A} 的逆矩阵是唯一的。因为假如任何一个矩阵 \mathbf{B} 是 \mathbf{A} 的逆矩阵，根据定义有：

$$\mathbf{B} = \mathbf{I}\mathbf{B} = \mathbf{A}^{-1}\mathbf{A}\mathbf{B} = \mathbf{A}^{-1} \quad (4.21)$$

如果 \mathbf{A} 可逆则 \mathbf{A} 的列线性独立。因为假如 $\mathbf{a}_{*j=1\dots n}$ 线性相关，则存在一组不全为 0 的系数 w_1, w_2, \dots, w_n ，使得 $\sum_{i=1}^n w_i \mathbf{a}_{*i} = \mathbf{0}$ 。即存在向量 $\mathbf{w} = (w_1 \ \cdots \ w_n)^T \neq \mathbf{0}$ 使：

$$\mathbf{A}\mathbf{w} = \mathbf{0} \quad (4.22)$$

因为 \mathbf{A} 可逆，存在 \mathbf{A}^{-1} ：

$$\mathbf{w} = \mathbf{A}^{-1}\mathbf{A}\mathbf{w} = \mathbf{0} \quad (4.23)$$

这与 $\mathbf{w} \neq \mathbf{0}$ 矛盾。所以可逆矩阵 \mathbf{A} 的列 $\mathbf{a}_{*j=1\dots n}$ 一定线性独立。如果方阵 \mathbf{A} 的逆矩阵是 \mathbf{A}^T ，则称 \mathbf{A} 为正交矩阵：

$$\mathbf{A}\mathbf{A}^T = \mathbf{A}^T\mathbf{A} = \mathbf{I} \quad (4.24)$$

从（4.24）可以看出 \mathbf{A} 的列 $\mathbf{a}_{*j=1\dots n}$ 是单位向量且两两正交：

$$\begin{cases} \mathbf{a}_{*i}^T \mathbf{a}_{*j} = 0, & i \neq j \\ \mathbf{a}_{*i}^T \mathbf{a}_{*j} = 1, & i = j \end{cases} \quad (4.25)$$

也就是说，正交矩阵 \mathbf{A} 的列都是单位向量， $\|\mathbf{a}_{*j=1\dots n}\| = 1$ 。任意两列是正交的（夹角为 $\pi/2$ ）。因为 \mathbf{A} 可逆，所以 $\mathbf{a}_{*j=1\dots n}$ 线性独立，是 n 维线性空间 \mathbb{R}^n 的一组基。因为 $\mathbf{a}_{*j=1\dots n}$ 两两正交，还是单位向量，所以它们被称为 \mathbb{R}^n 的一组标准正交基。

如果一组向量 $\mathbf{x}_{i=1\dots n}$ 是线性独立的，可以通过施密特正交化过程构造一组正交的向量 $\mathbf{x}'_{i=1\dots n}$ 。构造过程是：

首先令 $\mathbf{x}'_1 = \mathbf{x}_1$ 。然后令：

$$\mathbf{x}'_2 = \mathbf{x}_2 - \frac{\mathbf{x}_2^T \mathbf{x}'_1}{\mathbf{x}'_1^T \mathbf{x}'_1} \mathbf{x}'_1 = \mathbf{x}_2 - \frac{\|\mathbf{x}_2\| \cos \theta_{21}}{\|\mathbf{x}'_1\|} \mathbf{x}'_1 \quad (4.26)$$

θ_{21} 是 \mathbf{x}_2 与 \mathbf{x}'_1 的夹角。 \mathbf{x}'_2 是 \mathbf{x}_2 减去 \mathbf{x}_2 向 \mathbf{x}'_1 的投影。 \mathbf{x}_2 与 $\mathbf{x}'_1 = \mathbf{x}_1$ 线性独立，它不是 \mathbf{x}'_1 的数乘，所以 \mathbf{x}'_2 不是零向量。而且容易验证 \mathbf{x}'_2 与 \mathbf{x}'_1 正交。再令：

$$\mathbf{x}'_3 = \mathbf{x}_3 - \frac{\mathbf{x}_3^T \mathbf{x}'_1}{\mathbf{x}'_1^T \mathbf{x}'_1} \mathbf{x}'_1 - \frac{\mathbf{x}_3^T \mathbf{x}'_2}{\mathbf{x}'_2^T \mathbf{x}'_2} \mathbf{x}'_2 = \mathbf{x}_3 - \frac{\|\mathbf{x}_3\| \cos \theta_{31}}{\|\mathbf{x}'_1\|} \mathbf{x}'_1 - \frac{\|\mathbf{x}_3\| \cos \theta_{32}}{\|\mathbf{x}'_2\|} \mathbf{x}'_2 \quad (4.27)$$

θ_{31} 是 \mathbf{x}_3 与 \mathbf{x}'_1 的夹角， θ_{32} 是 \mathbf{x}_3 与 \mathbf{x}'_2 的夹角。 \mathbf{x}'_3 是 \mathbf{x}_3 减去 \mathbf{x}_3 向 $\mathbf{x}'_1, \mathbf{x}'_2$ 张成空间的投影。如果 $\mathbf{x}'_3 = \mathbf{0}$ ，那么 \mathbf{x}_3 可以被 $\mathbf{x}'_1, \mathbf{x}'_2$ 线性表出，也就可以被 $\mathbf{x}_1, \mathbf{x}_2$ 线性表出，这与 $\mathbf{x}_{i=1 \dots n}$ 线性独立矛盾。故 $\mathbf{x}'_3 \neq \mathbf{0}$ 。容易验证 \mathbf{x}'_3 正交于 $\mathbf{x}'_1, \mathbf{x}'_2$ 。此过程继续下去，最终可构造一组正交向量 $\mathbf{x}'_{i=1 \dots n}$ 。这就是施密特正交化过程。将 $\mathbf{x}'_{i=1 \dots n}$ 的每一个向量除以各自的模，缩放到长度为 1，就得到了一组正交的单位向量。

4.1.3 特征值与特征向量

特征值和特征向量的概念不局限于方阵，但本书主要关注方阵。用方阵 \mathbf{A} 乘向量 \mathbf{x} 是在 \mathbb{R}^n 中进行一个变换，将 \mathbf{x} 变换成 \mathbf{Ax} 。例如矩阵：

$$\mathbf{R} = \begin{pmatrix} \cos \theta & \sin \theta \\ -\sin \theta & \cos \theta \end{pmatrix} \quad (4.28)$$

用 \mathbf{R} 乘向量 \mathbf{x} 等于将 \mathbf{x} 逆时针旋转 θ 度。这可以自行验证。任何方阵 \mathbf{A} 也改变不了零向量 $\mathbf{0}$ ，因为 $\mathbf{A}\mathbf{0} \equiv \mathbf{0}$ 。如果对于某非零向量 $\mathbf{v} \neq \mathbf{0}$ ， \mathbf{A} 只能改变 \mathbf{v} 的长度而不能改变其方向，即存在某个标量（可以为 0） λ ，有：

$$\mathbf{Av} = \lambda \mathbf{v} \quad (4.29)$$

则称 λ 是 \mathbf{A} 的特征值， \mathbf{v} 是 \mathbf{A} 的对于 λ 的特征向量。同一个特征向量不可能对应两个特征值。假如 $\lambda_1 \neq \lambda_2$ 都有 \mathbf{v} 是其特征向量：

$$(\lambda_1 - \lambda_2)\mathbf{v} = \lambda_1\mathbf{v} - \lambda_2\mathbf{v} = \mathbf{A}\mathbf{v} - \mathbf{A}\mathbf{v} = \mathbf{0} \quad (4.30)$$

$\lambda_1 - \lambda_2 \neq 0$ 且 $\mathbf{v} \neq \mathbf{0}$ ，所以式 (4.30) 是不可能的。但是同一个特征值可以对应多个特征向量。如果 \mathbf{v} 是 λ 对应的特征向量，容易验证 $k\mathbf{v}$ 也是 λ 对应的特征向量。线性独立的两个向量也有可能是同一个特征值对应的特征向量。

假如 λ 对应的特征向量 \mathbf{v} 和 \mathbf{w} 是线性独立的，即谁也不是另一个的数乘。那么 $k\mathbf{v} + l\mathbf{w}$ 也是 λ 对应的特征向量。这也很容易验证。如果特征值 λ 共有 k 个线性独立的特征向量，由它们线性组合而得的向量也是 λ 的特征向量。这 k 个线性独立的特征向量张成的 k 维线性空间称为 λ 对应的特征空间，其中所有向量都是 λ 的特征向量。

将式 (4.29) 变形。如果 λ 是 \mathbf{A} 的特征值，它必须满足对某个 $\mathbf{v} \neq \mathbf{0}$ ，有：

$$(\mathbf{A} - \lambda\mathbf{I})\mathbf{v} = \mathbf{0} \quad (4.31)$$

因为 $\mathbf{v} \neq \mathbf{0}$ ，所以 $\mathbf{A} - \lambda\mathbf{I}$ 的列线性相关。求 \mathbf{A} 的特征值和特征向量，就是求满足方程 (4.31) 的 λ 和 \mathbf{v} 。若要 $\mathbf{A} - \lambda\mathbf{I}$ 的列线性相关，则 $\mathbf{A} - \lambda\mathbf{I}$ 的行列式 $|\mathbf{A} - \lambda\mathbf{I}|$ 等于 0。本书没有涉及行列式，因为行列式与本书主线关系不大，加进来会影响流畅性。读者可以查阅任何一种线性代数教材。 $|\mathbf{A} - \lambda\mathbf{I}| = 0$ 是 λ 的 n 次方程。它有 n 个根（包括重根和复数根）。即 \mathbf{A} 有 n 个特征值（包括重复的以及复特征值）。求得了 λ ，就可以再求它对应的特征向量。

矩阵 \mathbf{A} 属于不同特征值的特征向量是线性独立的。现在证明这一点。 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k$ 是 k 个不同特征值 $\lambda_1, \lambda_2, \dots, \lambda_k$ 对应的特征向量。如果它们线性相关，则其中某一个 \mathbf{v}_s 可以被其他 $\mathbf{v}_{i \neq s}$ 线性表出：

$$\mathbf{v}_s = \sum_{i \neq s} a_i \mathbf{v}_i \quad (4.32)$$

因为 \mathbf{v}_s 是 \mathbf{A} 的特征向量，所以它不是零向量。那么 $a_{i \neq s}$ 一定不全为 0。另外根据特征值和特征向量的定义：

$$\lambda_s \mathbf{v}_s = \mathbf{A} \mathbf{v}_s = \sum_{i \neq s} a_i \mathbf{A} \mathbf{v}_i = \sum_{i \neq s} a_i \lambda_i \mathbf{v}_i \quad (4.33)$$

如果 $\lambda_s = 0$ ，那么 $\lambda_{i \neq s} \neq 0$ 。再加上 $a_{i \neq s}$ 不全为 0，说明 $\mathbf{v}_{i \neq s}$ 线性相关。在 $\lambda_s = 0$ 情况下我们将问题规模减小了 1。如果 $\lambda_s \neq 0$ ，有：

$$\mathbf{v}_s = \sum_{i \neq s} a_i \frac{\lambda_i}{\lambda_s} \mathbf{v}_i \quad (4.34)$$

于是式 (4.34) 等于式 (4.32)，所以有：

$$\sum_{i \neq s} \left(a_i \frac{\lambda_i}{\lambda_s} \mathbf{v}_i - a_i \mathbf{v}_i \right) = \sum_{i \neq s} a_i \left(\frac{\lambda_i}{\lambda_s} - 1 \right) \mathbf{v}_i = \mathbf{0} \quad (4.35)$$

因为都是不同的特征值，所以 $\lambda_{i \neq s} / \lambda_s - 1 \neq 0$ 。再加上 $a_{i \neq s}$ 不全为 0，说明 $\mathbf{v}_{i \neq s}$ 线性相关。在 $\lambda_s \neq 0$ 情况下我们也将问题规模减小了 1。这个过程持续下去，最终将只剩下两个向量 \mathbf{v}_i 和 \mathbf{v}_j 。他们分属不同的特征值 λ_i 和 λ_j 。且 \mathbf{v}_i 和 \mathbf{v}_j 线性相关，其中一个是另一个的数乘。不妨假设 $\mathbf{v}_i = k \mathbf{v}_j$ ，则 \mathbf{v}_i 也是 λ_j 的特征向量。之前已经证明，一个向量不可能同时属于两个不同特征值。这就推翻了最早的假设，证明了 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k$ 线性独立。

4.1.4 对称矩阵的谱分解

如果方阵 \mathbf{A} 满足：

$$\mathbf{A} = \mathbf{A}^T \quad (4.36)$$

如果 \mathbf{A} 的元素都是实数，则它是一个实矩阵。实矩阵的特征值都是实数，特征向量是实向量。为了证明这个结论，我们需要暂时离开实数域。

复数 $\lambda = a + bi$ 的共轭是 $\bar{\lambda} = a - bi$ 。

$$\lambda \bar{\lambda} = (a + bi)(a - bi) = a^2 + b^2 \geq 0 \quad (4.37)$$

只有当 $a = b = 0$ ，即 $\lambda = 0$ 时，才有 $\lambda \bar{\lambda} = 0$ 。否则 $\lambda \bar{\lambda} > 0$ 。对于两个复数 $\lambda = a + bi$ 和 $\xi = c + di$ ，有：

$$\lambda \xi = (ac - bd) + (bc + ad)i = \bar{\lambda} \bar{\xi} \quad (4.38)$$

把复矩阵 \mathbf{A} 的元素全都取共轭就得到 \mathbf{A} 的共轭 $\bar{\mathbf{A}}$ 。如果（复数） λ 和（复向量） \mathbf{v} 是 \mathbf{A} 的特征值及对应特征向量，由式 (4.38) 容易看出： $\bar{\lambda}$ 和 $\bar{\mathbf{v}}$ 是 $\bar{\mathbf{A}}$ 的特征值及对应特征向量。

$$\bar{\mathbf{A}}\bar{\mathbf{v}} = \mathbf{A}\mathbf{v} = \lambda\mathbf{v} = \bar{\lambda}\bar{\mathbf{v}} \quad (4.39)$$

因为 \mathbf{A} 是实对称矩阵，有 $\mathbf{A} = \bar{\mathbf{A}} = \mathbf{A}^T = \bar{\mathbf{A}}^T$ ，所以有：

$$\lambda\bar{\mathbf{v}}^T\mathbf{v} = \bar{\mathbf{v}}^T\lambda\mathbf{v} = \bar{\mathbf{v}}^T\mathbf{A}\mathbf{v} = \bar{\mathbf{v}}^T\bar{\mathbf{A}}^T\mathbf{v} = (\bar{\mathbf{A}}\bar{\mathbf{v}})^T\mathbf{v} = (\bar{\lambda}\bar{\mathbf{v}})^T\mathbf{v} = \bar{\lambda}\bar{\mathbf{v}}^T\mathbf{v} \quad (4.40)$$

因为 $\mathbf{x} \neq \mathbf{0}$ ，根据式（4.37） $\bar{\mathbf{v}}^T\mathbf{v} > 0$ 。所以 $\lambda = \bar{\lambda}$ ，即 λ 是实数。 \mathbf{A} 是实矩阵， λ 是实数，所以 \mathbf{v} 一定是实向量。这就证明了实对称矩阵的特征值都是实数，特征向量是实向量。后文谈到矩阵都是实矩阵。

所以实对称矩阵 \mathbf{A} 有 n 个实特征值（可重复）。有一个结论我们不加证明：如果 λ 是 \mathbf{A} 的 k 重特征值（方程 $|\mathbf{A} - \lambda\mathbf{I}| = 0$ 的 k 重根），则 λ 对应的特征空间是 k 维，即对于 λ 能找到 k 个线性独立的特征向量。